

Contexto

En esta presentación se comparan los papers proporcionados, que tratan de la “computación afectiva” y modelos utilizados, especialmente de supervisor learning. Las comparaciones se centrarán en las referencias 2, 3 y 4.

Metodología de búsqueda

Texto encontrado en Google Scholar.

Términos Preliminares

- **Affective Computing:** Rama del estudio y desarrollo de la inteligencia artificial que hace referencia al diseño de sistemas y dispositivos que pueden reconocer, interpretar y procesar emociones humanas.
- **SVM**, Support Vector Machines: Método de aprendizaje supervisado utilizado ampliamente para tareas de clasificación y regresión. Funciona correlacionando datos a un espacio de características de grandes dimensiones de forma que los puntos de datos se puedan categorizar, incluso si los datos no se puedan separar linealmente de otro modo.
- **Autoencoder Neural Network:** three-layer neural network, which sets the target values to be equal to the input values. Arquitectura de NN con un "cuello de botella" en la red que fuerza una representación de conocimiento comprimida de la entrada original. El modelo de autoencoder ideal equilibra lo siguiente: es lo suficientemente sensible a las entradas como para construir una reconstrucción precisa y lo suficientemente insensible a las entradas como para que el modelo simplemente no memorice o sobreajuste los datos de entrenamiento.
- **Denoising autoencoders** (DAE): modificación del autoencoder original en la que, en lugar de proporcionar la entrada original, le damos una versión corrupta o ruidosa de la entrada al codificador, mientras que la pérdida del decodificador se calcula solo en relación con la entrada original. Esto da como resultado un aprendizaje eficiente de los autoencoders y se reduce significativamente el riesgo de que el autoencoder se convierta en una función de identidad.
- **Feature Map:** Para CNN, una matriz o cuadrícula bidimensional de números resultante de la aplicación de filtros convolucionales (también llamados núcleos) a una imagen de entrada o a un mapa de características de una capa anterior.
- **SSL:** Self-supervised learning

Comparación

[2] Affective Computing: a review	[3] Deep learning for sentiment analysis	[4] A survey and comparative study of tweet sentiment analysis via semi-supervised learning
Su principal enfoque es la computación afectiva, es decir, reconocimiento e interpretación de las emociones humanas. Busca cómo un modelo puede detectar emociones desde diferentes medios (expresiones faciales, voz, señales fisiológicas). También investiga sobre sus posibles aplicaciones.	Este se enfoca en el análisis de sentimientos utilizando modelos de deep learning (CNN, RNN, LSTM y transformadores) y cómo éstas han servido para la clasificación de sentimientos y polaridades (positivo, negativo, neutral) en el lenguaje natural.	Este documento es un poco más práctico con el análisis de sentimientos, pues trata de analizar tweets usando semi-supervised learning con sus desafíos, como la brevedad, lenguaje coloquial y uso de sarcasmo que característico de los tweets. En esta investigación utilizan datos tanto etiquetados como no etiquetados para mejorar la precisión del modelo.
Examina varios métodos multimodales que, en parte, usan redes neuronales profundas, además de usar métodos supervisados y no supervisados	Examina únicamente técnicas de deep learning para procesamiento de texto.	Valora los beneficios del aprendizajes semi-supervisado, además de técnicas como self-training y co-training para datos no etiquetados.

Comparación

En Ref. 4 se utilizan tres métodos diferentes de semi-supervised learning:

- **Graph-based:** Utilizan grafos para representar las relaciones entre los tweets etiquetados y no etiquetados. Las etiquetas se propagan a través del grafo para inferir las etiquetas de los tweets no etiquetados.
- **wrapper-based** (como self-training and co-training): Utiliza un algoritmo de aprendizaje supervisado de forma iterativa. En cada iteración, una determinada cantidad de instancias no etiquetadas se etiqueta mediante la función de decisión que se aprende y se incorpora a los datos de entrenamiento. A partir de sus propias predicciones y de los datos etiquetados ya disponibles, el modelo de clasificación se vuelve a entrenar para la siguiente iteración.
- **Topic-based:** Los dos métodos anteriores solo utilizan información de manera local, mientras que este analiza tanto el tema como el sentimiento de una muestra.

Referencias

- [1] Affective Computing: From Laughter to IEEE
- [2] Affective Computing: a review
- [3] Deep learning for sentiment analysis
- [4] A survey and comparative study of tweet sentiment analysis via semi-supervised learning